

Projet de génération et de détection en IA

IA02 - P24 - Projet Informatique

Rapport à rendre avant le 20 juin

Codes à rendre avant le 28 juin

Soutenances le vendredi 21 juin

1 Introduction

Le projet d'IA02 a une double vocation ; d'une part, il doit vous permettre de vous confronter à la pratique dans le cadre d'un "réel" projet de *Data Science*. Le plus gros du travail concerne donc l'IA, mais les aspects de prétraitements, de la curation, d'affichage, etc. . . .ne seront pas à négliger. Par ailleurs ce projet doit aussi vous permettre de progresser en étant confronté à des problèmes réels pour lesquels il n'existe pas de solutions préétablies, pas de correction, etc. . . .Vous avez le droit de vous aider de toutes les informations que vous trouverez, mais vous devez aussi être capable de justifier les choix et de mesurer la pertinence des solutions techniques.

Ce qui implique que si votre travail est bien fait, il pourra être utilisé dans des présentations de travaux de recherches. Cette pédagogie "en confrontant les étudiants à un challenge important" sera également évaluée. Par contre cela implique de travailler sur de vraies jeux de données qui sont soumis à confidentialité. Vous ne pourrez pas non plus publier votre code (en tout cas, pour l'instant).

2 Description des sujets proposés / conseillés

Nous vous proposons cette année 4 sujets ; bien que vous ayez le droit de prendre un autre sujet à votre convenance (en discuter avec le respo UE pour validation), les sujets proposés ont été rigoureusement sélectionnés afin de correspondre à un niveau de difficulté acceptable ainsi que de vous apporter les compétences nécessaires.

- **Détection d'activité de peptides d'élastine** : l'élastine est un constituant important du corps se trouvant entre les cellules. Dans les parois vasculaires, sa présence est cruciale pour permettre l'absorption de la pression due aux battements cardiaques. Il est supposé que la dégradation de l'élastine, en formant ainsi des peptides, peut être un marqueur chimique activant des mécanismes de réparation. Dans le présent cas, 12 trajectoires de peptides d'élastine vous sont données ; 6 donne lieu à une activité biologique, mais 6 ne semble pas. Votre but est de pouvoir identifier une "conformation spatiale" des atomes de ces molécules qui serait la clé de génération de l'activité biologique. Il conviendra de compléter la détection par une génération de trajectoires pour ces peptides.
- **Détection d'anomalie thermique dans les cœurs de centrales nucléaires** : la surveillance de la température du cœur d'une centrale nucléaire est un élément crucial pour sa sécurité. Nous

vous donnons des données de mesure de la température pour chacun des assemblages (les crayons de combustibles) utilisés dans le cœur du réacteur superphoenix à la fin de sa vie. Par ailleurs, une modélisation de l'impact que pourrait avoir un blocage total et instantané du fluide caloporteur sur l'un des assemblages est également fournie. Le projet consiste à générer des données simulant un défaut et détecter le plus rapidement possible ce défaut.

- **Détection d'attaque réseau dans un fournisseur de cloud** : une attaque de type Dos (*Denial of Service*) est très facile à mettre en œuvre, il s'agit simplement de saturer la victime ciblée sous une énorme quantité de requêtes. Cependant, un utilisateur unique ne disposera pas d'une grande puissance d'attaque en raison du débit limité de sa connexion ; en outre il sera rapidement identifié. Le cloud offre un levier majeur pour ce type d'attaque, il est en effet facile de louer une douzaine de machines et de lancer des attaques de type DDoS (*distributed DoS*) à l'aide de ces machines. Le problème est qu'un hébergeur de cloud n'a pas la possibilité de savoir exactement ce que font ses clients. Aussi nous proposons de détecter les attaques DDoS à la source en utilisant les données disponibles pour l'hébergeur de cloud concernant l'activité des machines (utilisation, CPU, mémoire, I/O ...). Les données fournies sont issues de PlanetLab, elle regroupe environ 40 machines hébergeant une 40 utilisateurs distribués sur ces machines parmi lesquels l'attaquant UTT...Ce jeu de données devra être complété d'un générateur de données de trafic légitime et d'attaque.
- **Détection d'anomalie de surface à partir d'images de roues** : la qualité d'une roue est également jugée à son aspect visuel. La production de roue en France étant couteuse, il est judicieux de cibler un marché de qualité et, donc, d'éviter tous les défauts visuels sur les roues produites. Nous vous proposons une large base d'images de roues de différentes formes et tailles. Malheureusement, ne disposant que de peu de roues contenant un défaut visuel, il vous faudra générer des défauts afin de proposer le détecteur le plus robuste possible.

3 Description des projets et des livrables

Vous êtes relativement libres dans la façon d'aborder ces projets. Votre but est de pouvoir disposer en fin de semestre des codes pour le prétraitement des fichiers de données, une solution de génération de données et une solution de détection du problème choisi.

Vous devez fournir un code qui fonctionne, c'est-à-dire présenter une démonstration permettant la génération de données synthétiques et la détection en utilisant les méthodes de *deeplearning* / d'IA présentées en cours.

Vous devrez présenter un état d'avancement informel lors de la semaine des médians (pas de présentation PowerPoint, mais simplement indiqué où vous en êtes, et votre planning de travail prévisionnel). Ce qui compte ce n'est pas tant la "performance" des résultats obtenus à la fin que la méthode mise en œuvre, les solutions techniques proposées : c'est surtout votre capacité à aborder un problème "réel", de grande ampleur et sans solution prédéfinie qui sera évaluée.

4 Questions pratiques et autres détails

Il est conseillé de réaliser 3 groupes de 5 étudiants.

Une légère différence de population dans chaque groupe est possible, mais, par exemple, il n'est pas envisageable d'avoir un groupe avec 2 étudiants ou un groupe de 7.

La constitution des groupes et le choix des sujets se font sur le document partagé suivant.

Votre enseignant est à votre disposition pour répondre à vos questions (par email, visio, ou part rendez-vous). Si toutes les questions relatives aux projets, son but, les données, etc. ...sont répondus, votre enseignant n'étant pas omniscient ...les questions techniques peuvent ne pas trouver de réponse immédiatement.

Pour cette première année, le choix du langage et du framework de programmation est libre : Python avec la bibliothèque *torch* est très fortement conseillé. Vous pourrez également consulter des sites tels que Huggingface et Kaggle pour y trouver des codes, des conseils et autres discussions.

Un rapport assez court est demandé : Par de formalisme excessif, il est simplement attendu que

- Une description de l'architecture proposée
- une justification des choix (architecture, implem...)
- une description des principales difficultés rencontrées
- les solutions mises en œuvre
- une présentation (critiques) des résultats : ce qui a bien marché, ce qui a moins marché, pourquoi...

Un rapport assez court est demandé, la taille préconisée pour le rapport serait de 5 à 10 pages ; il s'agit d'une recommandation, nullement d'une obligation

Le rapport est à remettre **avant** la soutenance. Le code peut être rendu, si nécessaire après la soutenance.

Il est attendu de votre part une présentation assez formelle durant laquelle vous devrez présenter (1) le sujet du projet (2) la façon d'aborder le problème (3) les grandes étapes de votre projet (4), les architectures mises en œuvre, en veillant à décrire les outils utilisés et à justifier vos choix.

Enfin, vous avez beaucoup de liberté pour faire plus et/ou différemment dans votre projet. Ce qui vous est demandé est un "minimum", mais vous pouvez aller plus loin.

Je réponds volontiers aux questions (par email, visio ou part rendez-vous), mais ne ferais pas le projet à votre place ... bon courage !