

See discussions, stats, and author profiles for this publication at: <https://www.researchgate.net/publication/376646222>

Radar detection and classification of minidrones using a lightweight neural network

Conference Paper · November 2023

CITATIONS

0

READS

107

9 authors, including:



Jean-François Degurse

20 PUBLICATIONS 116 CITATIONS

SEE PROFILE



Guillaume Point

Stellantis

34 PUBLICATIONS 693 CITATIONS

SEE PROFILE



Détection et and identification radar de mini-drones à l'aide d'un réseau de neurone léger

Jean-François Degurse, Pierrick Richard, Ronan Guillamet, Judie Guegan, Guillaume Point, Ezequiel Centofanti, Alain Peden, Vincent Muller, Yves Audic

► To cite this version:

Jean-François Degurse, Pierrick Richard, Ronan Guillamet, Judie Guegan, Guillaume Point, et al.. Détection et and identification radar de mini-drones à l'aide d'un réseau de neurone léger. Conference on Artificial Intelligence for Defense, DGA Maîtrise de l'Information, Nov 2023, Rennes, France. hal-04328548

HAL Id: hal-04328548

<https://hal.science/hal-04328548>

Submitted on 7 Dec 2023

HAL is a multi-disciplinary open access archive for the deposit and dissemination of scientific research documents, whether they are published or not. The documents may come from teaching and research institutions in France or abroad, or from public or private research centers.

L'archive ouverte pluridisciplinaire **HAL**, est destinée au dépôt et à la diffusion de documents scientifiques de niveau recherche, publiés ou non, émanant des établissements d'enseignement et de recherche français ou étrangers, des laboratoires publics ou privés.

Détection et and identification radar de mini-drones à l'aide d'un réseau de neurone léger.

[Jean-François DEGURSE](#)¹, [Pierrick RICHARD](#)¹, [Ronan GUILLAMET](#)¹, [Judie GUEGAN](#)¹, [Guillaume POINT](#)²,
[Ezequiel CENTOFANTI](#)³, [Alain PEDEN](#)³, [Vincent MULLER](#)⁴, [Yves AUDIC](#)¹

¹ THALES DMS FRANCE, 10 Av. 1ère Dfl, 29200 Brest, France

² STELLANTIS, Rte de Gisy, 78140 Vélizy-Villacoublay, France

³ IMT Atlantique, 655 Av. du Technopôle, 29280 Plouzané, France

⁴ Drone-Act, 28 ter Pl. du Dr Jean Queinnec, 56140 Malestroit, France

Résumé – La détection et la classification d’aéronefs à voilure tournante est un enjeu majeur dans les domaines de la défense et de la sécurité. En particulier, la prolifération de drones multi-rotor de petite taille, modifiés pour des missions d’attaque ou d’observation sur des théâtres d’opérations militaires, représente une menace croissante. A partir de moyens compacts et embarqués, les méthodes les plus utilisées pour détecter ces menaces, et éventuellement reconnaître, sont le systèmes optiques et acoustiques [1][2]. L’utilisation d’un radar en complément de ces systèmes peut améliorer les performances de détection et de classification. En effet, par rapport à une caméra optique, il est tout-temps et n’exploite pas sa résolution angulaire pour faire l’identification de la cible, et en comparaison d’un capteur acoustique, ses signaux évoluent dans un environnement moins bruité. Lorsque les contraintes SWAP (encombrement, poids, et consommation) n’est pas une contrainte forte, les radars très utilisés pour la détection de mini-drones [3][4]. En radar, pour classifier le drone en tant que tel, il est possible d’utiliser les signaux issus de sa signature micro-Doppler, qui rassemble les contributions de toutes les parties mobiles de l’aéronef, tel que les rotors. En fonction de la nature de la cible, cette signature peut être assez complexe mais peut être exploitée afin de détecter et identifier des drones à voilure tournante. Nous nous intéressons dans cet article, à l’utilisation d’un algorithme de réseau de neurones peu profond pour détecter et reconnaître différents types de drones à partir d’un radar très compact. Afin de disposer d’une base de données suffisamment grande, et pour que ces données ne soient pas protégées, nous utiliserons un radar sur étagère à bas coût fonctionnant en mode CW.

Abstract – Rotorcraft detection and classification is a major issue for defense and security. In particular, the proliferation of small multi-rotor UAV, sometimes modified for attack or observation missions in military operation field represents a growing treat. Small and embeddable mini-UAV detection systems are usually based on optical and acoustic sensors [1][2]. The use of a radar in addition of these sensors can increase detection and classification performance. Indeed, when compared to optical camera, radar is not affected by weather condition and does not use its angular resolution to perform target identification, and when compared to acoustic sensors, relies on a less noisy environment. When SWAP (Size, Weight And Power) is not a strong constraint, radars are widely used for drone detection [3][4]. In radar, to perform drone recognition, it is possible to use the signal of its micro-Doppler signature, which gathers all contributions of moving part of the drone like rotors. In the paper, we focus on the use of a lightweight neural network algorithm to detect and identify different mini-UAV on small-sized radar data. In order to get a large amount of non-classified data, we chose to use a commercial off-the-shelf K-band radar in continuous wave mode.

1 Introduction

1.1 Contexte

Face à la prolifération des menaces, des systèmes radar très courte portée ont émergées afin de doter certains blindés de protection active. Ces radars ont pour but de détecter, localiser et pister les menaces (roquettes, missiles anti-blindés) arrivant à grande vitesse sur le porteur afin de déclencher une contre-mesure [5][6].

Les conflits récents ont montré que les mini-drones constituent une menace aussi importante en étant utilisés pour larguer des explosifs ou directement comme vecteur portant la munition jusqu’à l’impact.

Par rapport aux menaces plus classiques, les vitesses d’approche sont plus faibles et les trajectoires sont moins linéaires, ce qui demande une adaptation du système de détection et des contre-mesures associées pour assurer leur interception.

Dans une première partie, nous détaillerons le modèle mathématique des signaux radars rétrodiffusés par un aéronef à voilure tournante, puis nous présenterons le protocole de mesure et d’enregistrement des données. Enfin nous présenterons les résultats en détection et en classification obtenus sur différents drones à l’aide d’un algorithme de machine learning nécessitant peu de ressources de calcul.

1.2 Modélisation des signaux radar d'une cible à voilure tournante

La signature radar d'un aéronef à voilure tournante peut se décomposer en 3 éléments [8] : le corps de l'aéronef, le hub du rotor et les pales du rotor.

Le corps de l'aéronef, également appelé cellule, qui possède une signature Doppler simple, dépendant de sa vitesse radiale relative par rapport au radar. La surface équivalente radar (SER) du corps de l'aéronef peut être modélisé de différentes façons, par exemple en prenant une loi de fluctuation Swerling 1. Le signal correspondant s'exprime donc de la manière suivante :

$$s_{corps} = \sqrt{\sigma_{corps}(t)} e^{i(\varphi_0 + \varphi_{corps}(t) + 2\pi f_D t)} \quad (1)$$

avec $\sigma_{corps}(t)$ la surface équivalente radar instantanée de la cellule, $\varphi_{corps}(t)$ une variable uniformément répartie sur $[0; 2\pi[$, φ_0 une phase à l'origine constante prenant en compte le temps la propagation aller-retour du radar vers la cible et f_D le décalage en fréquence dû à l'effet Doppler défini par :

$$f_D = \frac{2V_{rr}}{\lambda} \quad (2)$$

Le hub, également appelé moyeu, est le système de fixation des pâtes sur l'arbre de transmission du rotor. Cette partie est très signante sur hélicoptère et sur les drones de grandes tailles mais est de conception beaucoup plus simple sur les mini-drones. Cet élément possède une signature caractéristique, avec une décroissance exponentielle de la densité spectrale de puissance autour de la fréquence du corps de l'aéronef. En conséquence, il peut être modélisé comme un nuage de points réfléchissants. Il est composé de M points pour un angle donné du disque comprenant le rotor. La distance radiale d'un point sur ce disque est définie par une fonction de densité suivant une loi exponentielle :

$$f_r(r) = \frac{2}{r_{hub}} e^{-2r/r_{hub}} \quad (3)$$

La répartition angulaire des points suit la fonction de densité f_θ suivante :

$$f_\theta(\theta) = \frac{1}{4} \mathcal{U}\left(\left[\theta_{pale} - \frac{\pi}{N}, \theta_{pale} + \frac{\pi}{N}\right]\right) + \frac{3}{4} \mathcal{N}(\theta_{pale} + \beta, \Delta\theta)$$

où $\mathcal{U}$ représente la loi uniforme, $\mathcal{N}$ la loi normale, θ_{pale} est l'angle de la pale considérée à $t=0$, β est un décalage angulaire propre à chaque aéronef et $\Delta\theta$ un terme de correction de l'ordre de 1° . Enfin, la répartition verticale des points peut être approximée par une répartition uniforme :

$$f_z(z) = \mathcal{U}([0, h_{hub}]) \quad (4)$$

avec h_{hub} la hauteur du hub. Une fois que les positions initiales des points brillants du hub sont fixées, ils sont mis en rotations à la même vitesse de rotation que les N pales. La réponse totale du hub est alors :

$$s_{hub}(t) = \alpha_{hub} e^{i(\varphi_0 + \varphi_r + 2\pi f_D t)} \sum_{j=1}^{MN} e^{-2i\vec{k}_r \cdot \vec{r}_j} \quad (5)$$

où la réflectivité α_{hub} est ajustée tel que $var(s_{hub}(t)) = \sigma_{hub}$, σ_{hub} étant la SER du hub.

Les pales peuvent être essentiellement vues comme des réflecteurs spéculaires périodiques bien que dans certains cas, elles incluent également une composante continue provenant de l'extrémité de la pale qui peut avoir une réflectivité quasi-isotrope. Elles peuvent être modélisées comme un objet unidimensionnel de longueur L avec une réflectivité constante α par unité de longueur avec une vitesse angulaire Ω_r . Elles sont fixées à une distance r_{hub} de l'axe de rotation. Les forces aérodynamiques et de pesanteur induisent une déformation lors des phases de vol selon l'axe Z , qui peut s'exprimer par $z_b(r, \theta(t))$ comme présenté sur la Figure 1.




Figure 1 : Schéma présentant la déformation d'une pale selon l'axe Z.

La position du point M, élément unitaire constituant la pale s'exprime alors :

$$\vec{O_r M}(t) = r \cos(\theta(t)) \vec{e}_{xr} + r \sin(\theta(t)) \vec{e}_{yr} + z_b(r, \theta(t)) \vec{e}_{zr}$$

Pour des rotors de petite taille, comme les mini-drones, les pales peuvent être considérées comme une tige droite et le terme $z_b(r, \theta(t))$ peut être négligé [5]. Pour les rotors de grande taille, l'expression de z_b doit être prise en compte, et un phénomène d'oscillation se crée lors des phases de vol en mouvement, ce qui rend l'expression plus complexe [3]. Dans notre cas, nous pouvons donc considérer l'expression du signal d'une pale de la manière suivante :

$$s_{pale}(t) = \alpha_{pale} e^{i(\varphi_0 + \varphi_r + 2\pi f_D t)} \int_{r_{hub}}^L e^{-2i\vec{k}_r \cdot \vec{O_r M}(t)} dr$$

Il faut noter que la valeur de α_{pale} sera différente entre pale en mouvement avancement et une pale en mouvement reculant parce que les bords d'attaque des pales diffèrent forcément de part et d'autre.

Le signal rétrodiffusé par un rotor s'écrit donc :

$$s_{rotor}(t) = s_{hub}(t) + \sum_{i=1}^{N_{rotor}} s_{pale} \left(t + (i-1) \frac{2\pi}{N\Omega_r} \right) + s_{extremite} \left(t + (i-1) \frac{2\pi}{N\Omega_r} \right)$$

Finalement, la réponse totale d'un aéronef à voilure tournante est :

$$s_{drone}(t) = s_{corps}(t) + \sum_{j=1}^{N_{rotor}} r_{rotor,j}(t) \quad (6)$$

Pour la plupart des mini-drones le nombre de rotors, $N_{rotor} = 4$ ou $N_{rotor} = 6$, et sur les hélicoptères $N_{rotor} = 2$.

Lorsque le radar a un échantillonnage de la fréquence Doppler bien plus important que la période de rotation du rotor, les flashes des différentes pales sont clairement visibles sur le spectrogramme. La figure ci-dessous présente des spectrogrammes d'un même hélicoptère obtenus à partir d'un radar aéroporté en bande X en enregistrement réel et en simulation.




Figure 2 : Spectrogramme d'un hélicoptère obtenu par un radar aéroporté en bande X (en haut) et par simulation (en bas).

Les flashes de pales provenant du rotor principal ainsi que du rotor anti-couple sont très nettement visibles. Les techniques radar classiques de détection de pic dans un environnement de bruit gaussien donnent de bons résultats pour la détection d'hélicoptères [9].

Dans le chapitre suivant, nous verrons que face à un rotor tournant beaucoup plus vite et en utilisant un radar

beaucoup moins performant, les spectrogrammes obtenus montrent que les flashes de pales sont beaucoup plus difficiles à discerner, rendant les méthodes évoquées précédemment caduques.

1.3 Enregistrement de signaux radar et analyse du micro-Doppler sur pales de référence

Afin d'obtenir facilement un grand volume de données non protégées sur différents drones à un coût réduit, nous faisons le choix d'utiliser un radar bande K à 24 GHz en mode continu (CW). Bien que n'ayant pas de capacité à mesurer la distance, cette forme d'onde présente l'avantage d'obtenir une signature micro-Doppler avec un échantillonnage rapide, là où une forme d'onde radar FMCW (Frequency Modulated Continuous Wave) rendrait la signature bien plus complexe. En effet, une forme d'onde radar à impulsions nécessiterait une fréquence de répétition des impulsions très importante afin d'obtenir un échantillonnage en fréquence Doppler suffisant, ce qui n'est pas accessible pour un radar bas coût.




Figure 3 : Diagramme d'un radar FMCW/CW. Source: Charly Whisky, Pierre CB.

Les radars FMCW/CW [10] compacts sont utilisés dans de nombreuses applications : capteurs de mouvement pour l'ouverture automatique des portes, contrôles de vitesse par les forces de l'ordre, assistance à la conduite pour l'automobile. En mode CW, leur fonctionnement est très simple : une fréquence fixe est émise par une antenne d'émission, tandis que le signal reçu par l'antenne de réception est directement démodulé par le signal émis avant d'être numérisés. Tous les signaux renvoyés par des objets fixes par rapport au radar ont donc une fréquence nulle, alors que les objets mobiles renvoient, à cause de l'effet Doppler, des signaux décalés à une fréquence f_D définie dans l'Eq. (1). Notons que plus la longueur d'onde est faible, plus le décalage Doppler sera important pour une vitesse donnée. Cela avantage un radar en bande K par rapport à des radars fonctionnant en bande plus basse comme les radars en bande X. Le traitement du signal consiste simplement à appliquer une transformée de Fourier glissante avec un nombre de points qui doit être

sélectionné en fonction de la nature du signal, avec un recouvrement plus ou moins important, et éventuellement une pondération, afin d'obtenir un spectrogramme temps-fréquence.

Le radar utilisé pour l'acquisition de données est composé d'une carte d'évaluation RFBeam ST200 munie d'un module K-MC1.




Figure 4 : Carte d'évaluation RFBeam ST200

Les paramètres du radar utilisés pour les acquisitions avec ce module sont les suivants :

- $P_e = 16,5 \text{ dBm}$
- Fréquence d'émission = $24,125 \text{ GHz}$
- Ouverture angulaire = $12^\circ \times 25^\circ$
- Fréquence d'échantillonnage = 125 kHz

Avant de faire des enregistrements face à des drones, le radar a d'abord été utilisé pour enregistrer le signal deux hélices dont nous maîtrisons la vitesse de rotation. La rotation des deux hélices est effectuée avec un moteur de 5V contrôlé par une puce L293D et un Arduino. Pour cet enregistrement, la vitesse de rotation de l'hélice est de 5000 rpm (83 Hz). A la fréquence d'échantillonnage de 125 kHz, un tour complet prend donc environ 1500 points.



Figure 5 : Hélices à 2 et 3 pales recouvertes de cuivre pour augmenter leur réflectivité

Le nombre de points utilisé pour la transformée de Fourier (DFT) est un paramètre crucial. Pour un signal continu et stable en fréquence, plus le temps d'intégration est important, plus la résolution

fréquentielle et le rapport signal sur bruit (RSB) augmente.

Pour un signal non continu ou variable en fréquence, un temps d'intégration trop élevée entraînera une défocalisation du signal qui apparaîtra alors comme flou sur le spectrogramme. Pour ces premières mesures, nous prenons 256 points d'intégration.

Les figures suivantes présentent les spectrogrammes obtenus sans couverture cuivre sur la pale, et avec une seuil pale recouverte de cuivre. Nous observons comme prévu une intensité plus importante du flash de la pale cuivrée.




Figure 6 : Spectrogramme obtenu sur hélice sans cuivre (en haut) et sur hélice avec une pale recouverte de cuivre (au milieu) et avec les 3 pales recouvertes de cuivre (en bas)

La Figure 7 suivant présente le spectrogramme obtenu face à l'hélice à deux pales recouvertes de cuivre.




Figure 7 : Spectrogramme d'une hélice à deux pales

D'après l'amplitude du signal dans le spectrogramme, on peut obtenir le décalage Doppler et donc, en appliquant l'équation (1), la vitesse tangentielle maximale des pales, ce qui nous donne une valeur d'environ 19 m/s. Ensuite, on peut obtenir la fréquence de rotation des pales à partir de la fréquence des flashes sur le spectrogramme. On obtient alors une période de rotation d'environ 14 ms, c'est-à-dire 4300 rpm. Avec ces deux grandeurs, on peut estimer la longueur des pales de la façon suivante :

$$r = \frac{V_{tangentielle}}{2\pi f_{angulaire}} = 4,2cm$$

La valeur calculée pour la longueur des pales est proche de la valeur réelle, soit environ 4 cm.

1.4 Enregistrement de signaux radar face à des drones et traitement du signal

La campagne de mesures face à des mini-drones a été réalisée en intérieur, dans un gymnase. De ce fait, en l'absence de signal GPS, nous ne disposons de la position des drones lors de l'enregistrement. Les enregistrements ont été effectués face à 7 drones différents : DJI Inspire, DJI Mavic 2, DJI Mavic Mini, DJI Mavic Air, DJI Matrice, Drone FPV, Drone-Act SeeAll.

Pour obtenir les spectrogrammes, nous intégrons le signal sur 512 points. L'horizon temporel définissant la taille des spectrogrammes envoyés à l'algorithme de reconnaissance sera déterminé en fonction des performances de classification. Il existe également deux techniques pour normaliser l'échelle de puissance des spectrogrammes : soit une fenêtre fixe prédéterminée, soit une fenêtre variable prenant le minimum et le maximum de chaque spectrogramme.

Les Figure 8 et Figure 9 présentent les spectrogrammes obtenus pour deux mini-drones avec un horizon temporel de 146 points. Dans la suite, nous avons choisi un horizon temporel de 15 points. Cela permet de segmenter le signal enregistré au cours des vols de façon plus conséquente. C'est un compromis entre le nombre

d'images dans la base de données et la quantité d'informations présente sur chacune. Les tenseurs en entrée du réseau de neurones seront donc de dimension (512,15). La normalisation d'échelle en fenêtre variable sera retenue. Finalement, le tableau suivant présente un récapitulatif de la base de données à notre disposition :

Nom du drone	Nombre d'images
DJI Mavic 2	10873
DJI Mavic Air	9267
DJI Inspire	9342
DJI Mini	13508
Drone FPV (Racer)	13492
Drone-Act See-All	9637
DJI Matrice	10247
Bruit thermique	28773

Tableau 1 : Base de données de signaux radar




Figure 8 : Spectrogramme d'un DJI Mavic 2




Figure 9 : Spectrogramme d'un DJI Inspire

2 Algorithmes de détection et classification par machine learning

2.1 Méthode proposée

Nous avons ainsi obtenu une base de données d'environ 80000 images temps-fréquence de dimension (512,15). Cette base de données sera aléatoirement séparée en une base d'apprentissage (60%), une base de test (20%) et une base de validation (20%). Notre objectif sera d'étudier dans un premier temps la détection d'un drone, c'est-à-dire le fait de différencier un drone du bruit thermique. Pour ce faire nous utiliserons un réseau de neurones qui sera décrit plus loin. C'est donc une classification binaire. Dans un second temps nous étudierons l'identification du drone (parmi les 7 classes présentées) grâce à ce même réseau de neurones. Cette fois-ci nous nous retrouverons face à un problème de classification multi-classe.

Différents algorithmes proposés dans la littérature montrent que les réseaux de neurones permettent d'obtenir de très bonnes performances en classification sur mini-drones [11][12]. Nous nous concentrons dans cette étude sur un réseau de neurones peu profond de manière à limiter autant que possible la complexité calculatoire du traitement. Il est constitué de différentes couches de convolution et de pooling ainsi que de connexions résiduelles qui ont permis d'améliorer les performances de l'ordre de 5%. Le réseau de neurones convolutif utilisé est illustré sur le Tableau 2.

Couche	Type	Taille	Kernel	Filtres
1	Input	512 x 15	-	-
2	Conv2D	512 x 15	3 x 3	32
3	Conv2D	512 x 15	3 x 3	32
4	Add	512 x 15		
5	Max-pool	255 x 7	2 x 2	
6	Conv2D	255 x 7	3 x 3	32
7	Conv2D	255 x 7	3 x 3	32
8	Add	255 x 7		
9	Max-pool	127 x 3	2 x 2	
10	Conv2D	127 x 3	3 x 3	32
11	Conv2D	127 x 3	3 x 3	32
12	Add	127 x 3		
13	Max-pool	64 x 2	2 x 2	
14	Conv2D	64 x 2	3 x 3	32
15	Conv2D	64 x 2	3 x 3	32
16	Add	64 x 2		
17	Max-pool	32 x 1	2 x 2	
18	Flatten	1 x 1024	-	-
19	Dense	1 x 2	-	-
20	Softmax	1 x 2	-	-

Tableau 2 : réseau de neurones utilisé

Le modèle retenu a été entraîné en utilisant une taille de batch de 32 avec l'optimiseur Adam. L'apprentissage

s'effectuera sur 20 itérations, en mettant en œuvre l'arrêt conditionné de l'entraînement.

2.2 Entraînement et résultats en détection

Une fois les hyper paramètres de la base de données ainsi que l'architecture du réseau de neurones fixés, nous pouvons réaliser la phase d'entraînement du réseau de neurones. Pour rappel, la détection est une discrimination binaire entre la présence d'un drone et l'absence de drone (bruit thermique seul). Les performances obtenues au cours de l'entraînement sont résumées dans la matrice de confusion et les courbes d'apprentissage présentées sur la Figure 10.




Figure 10 : matrice de confusion pour la détection binaire (en haut) et courbes d'apprentissage (en bas)

Lorsque que le réseau de neurones est correctement entraîné, il est possible de l'utiliser tel quel (les poids sont alors figés) pour réaliser la tâche de détection. Cette partie se rapprochera de ce que l'on retrouve dans un contexte opérationnel puisque l'algorithme traite des passes complètes de vol, en prenant en compte la dimension temporelle. Dans nos essais, les drones effectuent des aller-retours sur une distance d'une trentaine de mètre, mais nous n'avons pas de mesure précise de la distance, du fait de l'utilisation du mode CW. Il nous est cependant possible d'analyser l'allure de la moyenne locale des scores de détection au cours de

l'essai. Cette moyenne correspond à la moyenne du score en sortie du réseau de neurones sur une série d'images temps-fréquence consécutives.




Figure 11 : probabilité de détection du drone DJI Mavic 2 au cours du temps

En se concentrant sur le vol du Mavic 2 on peut observer que l'allure de la courbe de score du drone est tout à fait en accord avec les mouvements d'aller-retours qui ont été réalisés au cours des essais. On peut conclure que l'algorithme de classification se comporte comme attendu (aucune classification au-delà d'une certaine distance). Pour caractériser cette valeur de portée avec précision, il nous manque cependant la distance à l'instant $T \approx 30\text{UA}$. Nous pouvons cependant estimer qu'elle se situe à une vingtaine de mètre pour ce drone.

2.3 Entraînement et résultats en classification

De la même façon, en modifiant cette fois la couche de sortie du réseau de neurones convolutif, voici les performances obtenues en identification au cours de l'entraînement.




Figure 12 : matrice de confusion pour l'identification des drones




Figure 13 : courbes d'apprentissage pour le réseau de détection d'identification des drones

En utilisant la moyenne locale des scores de classification, nous chercherons à vérifier la robustesse de la classification à la distance.

2.4 Capacité de détection de nouveauté

Il existe de nombreux types de drones, qui sont parfois modifiés pour les besoins adverses, il sera sans doute difficile, voire impossible d'avoir une base de données exhaustive contenant tous les drones que l'algorithme sera amené à rencontrer. Il est donc important que la détection d'un drone soit robuste à un drone inconnu, c'est-à-dire un drone qui n'est pas présent dans la base de données d'apprentissage.

Pour cela, nous allons retirer toutes les données de l'un des drones de la base de données (le DJI Mavic 2 dans l'exemple qui suit). Nous allons donc reprendre la phase d'entraînement avec les données bruit thermique ainsi que celles de tous les autres drones sauf celles du drone étudié. Une fois l'entraînement terminé, nous allons utiliser le réseau de neurones pour tenter de détecter la présence d'un drone au cours du vol du drone DJI Mavic 2 qui est donc inconnu du réseau. Nous comparerons ensuite ces données avec le même vol lorsque le drone DJI Mavic 2 se situe bien dans la base de données d'apprentissage pour bénéficier d'une base initiale et quantifier l'intérêt d'avoir la base de données la plus complète possible. La Figure 14 présente les courbes de probabilité de détection avec et sans le drone Mavic 2 dans la base d'apprentissage.

Les deux courbes ont une allure similaire et nous remarquons que, logiquement, l'ajout du drone à la base de données d'apprentissage permet d'améliorer légèrement les performances. Avoir le drone cible dans la base de données d'apprentissage améliore donc sa détectabilité, mais son absence ne remet pas en cause l'utilisation de cet algorithme à des fins de détection.




Figure 14 : probabilité de détection face à un Mavic 2 avec et sans Mavic 2 dans la base d'apprentissage

2.5 Implémentation en temps réel

Les temps d'inférence de ces deux réseaux de neurones ont été mesurés sur différents GPUs NVIVIDIA. Le but est d'estimer la ressource de calcul nécessaire à l'utilisation de ces algorithmes. Il est en effet important de traiter les signaux radar reçus en temps réel afin d'identifier une menace et d'y répondre dans un délai le plus court possible.

Ces mesures ont été faites en utilisant uniquement un appel de prédiction dans le framework Tensorflow. Ces temps sont donc significativement supérieurs à ce que que serait une implémentation plus optimal utilisant par exemple TensorRT. Trois processeurs graphiques ont été évalués : carte RTX GeForce 2080 Ti, un module SoC NVIDIA Jetson Nano et sur un module SoC NVIDIA Jetson AGX Orin. Les temps d'inférence moyens sont les suivants :

Matériel	Temps d'inférence	TDP max
RTX GeForce 2080 Ti	13 ms	250W
Jetson Nano	860 ms	10W
Jetson Orin	70 ms	65W

Ces temps ne comprennent que l'inférence en elle-même. Ils ne sont donc pas négligeables par rapport à l'acquisition du signal qui est de 140 ms. Nous voyons néanmoins qu'avec une implémentation non optimisée, un module AGX Orin, qui est très adapté pour les systèmes embarqués compacts, permet de réaliser l'inférence en un temps deux fois plus court que l'acquisition des données.

3 Conclusion

Dans ce papier, nous avons montré que les signaux rétrodiffusés par un aéronef muni de rotors sont

complexes. Sur des données enregistrées à l'aide d'un radar compact à faible coût, il est néanmoins possible d'obtenir des performances intéressantes en détection et classification à l'aide d'un algorithme à base d'un réseau de neurones convolutif muni de connexions résiduelles. Une caractérisation plus fine des performances en fonction du rapport signal sur bruit reste toutefois à réaliser, mais ces premiers résultats de la combinaison entre un prétraitement temps-fréquence et de cette architecture de réseau de neurones permettent d'obtenir de bons résultats en détection et en identification au moyen d'une capacité de calcul limitée. Nous avons également montré que ce type d'approche est relativement robuste à l'absence du drone cible dans la base d'apprentissage.

Les travaux futurs porteront d'une part sur l'acquisition de signaux à partir de radars plus performants en extérieur, et d'autre part à l'étude du gain en temps d'inférence obtenu à l'aide d'une implémentation plus optimisée.

4 Bibliographie

Références

- [1] Liu, H., Wei, Z., Chen, Y., Pan, J., Lin, L., & Ren, Y. (2017, April). Drone detection based on an audio-assisted camera array. In 2017 IEEE Third International Conference on Multimedia Big Data (BigMM) (pp. 402-406). IEEE.
- [2] Mezei, J., Fiaska, V., & Molnár, A. (2015, November). Drone sound detection. In 2015 16th IEEE International Symposium on Computational Intelligence and Informatics (CINTI) (pp. 333-338). IEEE.
- [3] Á. D. de Quevedo, F. I. Urzaiz, J. G. Menoyo and A. A. López, "Drone Detection With X-Band Ubiquitous Radar," *2018 19th International Radar Symposium (IRS)*, Bonn, Germany, 2018, pp. 1-10, doi: 10.23919/IRS.2018.8447942.
- [4] Ochodnický, J., Matousek, Z., Babjak, M., & Kurty, J. (2017, May). Drone detection by Ku-band battlefield radar. In 2017 International Conference on Military Technologies (ICMT) (pp. 613-616). IEEE.
- [5] Wehling, J. H. (2005). Multifunction millimeter-wave systems for armored vehicle application. *IEEE transactions on microwave theory and techniques*, 53(3), 1021-1025.
- [6] Hudec, P., Raboch, J., Randus, M., Hoffmann, K., Holub, A., Svanda, M., & Polivka, M. (2009,

September). Microwave radar sensors for active defense systems. In 2009 European Radar Conference (EuRAD) (pp. 581-584). IEEE.

[7] Wey, P., Fleck, V., & Chanteret, P. Y. (2001, May). Analysis of active protection systems: when athena meets arena. In Proceedings of the 19th International Symposium on Ballistics.

[8] Point, G., Degurse, J. F., Savy, L., Montécot, M., & Milin, J. L. (2021). Modelling the radar signature of rotorcraft. *IET Radar, Sonar & Navigation*, 15(8), 867-88.

[9] Misiurewicz, J., Kulpa, K., & Czekala, Z. (1997). Analysis of recorded helicopter echo.

[10] Stove, A. G. (1992, October). Linear FMCW radar techniques. In *IEE Proceedings F (Radar and Signal Processing)* (Vol. 139, No. 5, pp. 343-350). IET Digital Library.

[11] Brooks, D. A., Schwander, O., Barbaresco, F., Schneider, J. Y., & Cord, M. (2018, June). Temporal deep learning for drone micro-Doppler classification. In *2018 19th International Radar Symposium (IRS)* (pp. 1-10). IEEE.

[12] Park, D., Lee, S., Park, S., & Kwak, N. (2021). Radar-spectrogram-based UAV classification using convolutional neural networks. *Sensors*, 21(1), 210